研究导航 · 2026-11-02

分类与证据说明

面向 Xinfeng Li 与实验室学生的阅读、选题和证据核对入口

短答案

建议从具体对象进入，例如记忆、工具、Skill、授权、网络安全 Agent、医疗 Agent、水印和蒸馏。网页把同一论文的主题、关键词、真实引用与实践来源连接起来，并给出八个主题的比较基线、验证终点和停止条件。它帮助缩小阅读范围，尚未批准任何一个新 idea 的新颖性。[C02][C06 – C14]

44	24	13	39
精选阅读入口	可交叉主题	实践来源	真实引用边

范围与证据

以既有 3,621 条记录为起点，补入经典基线与公开主页关联论文。当前共 3,639 条记录，88 条归类经人工复核；其余保留建议归类或未归类状态。人工核对分类、摘要核验、关键章节核读与阅读全文是不同工作。本轮未重新通读全部论文。[C01]

研究主体沿用 2025 – 2026 年资料，保留少量早期经典。2027 条目仅作为候选或作者声称录用的线索，默认重点队列不纳入这些条目。2026 年发表状态也按单篇列出的来源核查范围解释。[C14]

一次课题讨论如何使用

打开同目录的 index.html，选择主题，查看“当前选题判断”和“最近工作”。选两篇最强相关基线，检查它们已覆盖的条件；从实践卡确认失效终点是否仍然成立。能够写出同预算对照和停止条件后，再决定是否做小实验。[C02][C05]

> 本说明记录分类依据与研究判断。论文卡和完整来源定位在网页内按需打开。Citation 与 Star 只作辅助记录，不构成质量评分；总被引量未可靠完成版本去重。[C04][C14]

24个可交叉研究主题

主标签按受保护对象和机制确定。应用基线的交叉关联单独显示，例如医疗工作流使用记忆，不表示它已经研究记忆攻击或删除保证。

主题	纳入对象
外部内容注入	网页、邮件、文档、图像或工具结果中的不可信指令改变任务执行。
动作授权与执行	工具调用的身份、对象、目的、接收端、权限、确认、撤销和提交语义。
工具与MCP安全	工具注册、描述/schema、工具结果、MCP连接器、第三方服务和工具供应链。
Skill与工作流安全	可复用Skill包、指令资产、工作流/规划图、安装更新与执行范围。
长期记忆安全	Agent记忆的写入、检索、污染、跨会话累积、删除与来源约束。
检索与知识库安全	检索语料、向量库、排序、引用证据和RAG输出的完整性与鲁棒性。
多Agent协作安全	Agent间通信、委托、角色/身份、传播、合谋和协作中的信任边界。
Agent评测与审计	交互轨迹、可执行环境、审计器、攻击预算、真实动作结果和评判可靠性。
隐私推断与泄露	成员/属性/内容推断、模型反演、跨上下文披露、输入输出及侧信道隐私。
训练投毒与后门	训练数据、插件/LoRA、微调或数据蒸馏中的恶意影响、触发器及持久后门。
越狱与拒答校准	有害请求处理、越狱、过度拒答、知识边界拒答及安全对齐控制。
微调与模型变换	微调、量化、剪枝、合并及压缩后安全/隐私属性的保持、退化与恢复。
水印与归属验证	生成内容、模型或数据的水印、指纹、检测、归属、容量、伪造和移除。
蒸馏与反蒸馏	教师学生迁移中的安全/隐私传递、模型提取、复制防御、反蒸馏和授权学习。
网络安全Agent	用Agent/LLM执行漏洞发现、渗透测试、程序分析、告警调查、修复与网络协议分析。
医疗AI与医疗Agent	临床/医疗决策、证据推理、医疗Agent协作、患者隐私、安全失误和实际工作流验证。
人机协作与监督	用户监督、接管、授权理解、信任校准、工作负荷与人机协作质量。
生成内容安全与鉴伪	文本/图像/视频/音频生成内容审核、深伪检测、来源一致性及检测隐私。
音频与语音安全	音频LLM、语音识别/合成/声纹中的对抗、隐私、深伪与可信评测。
具身行动安全	机器人/自动驾驶动作、意图到行为、约束控制、物理后果和安全接管。
世界模型与安全规划	世界模型预测误差、不确定性、危险识别和闭环规划/策略安全。
隐私学习与遗忘	差分隐私、联邦学习、数据删除、模型/工具知识遗忘及可验证隐私保障。
推理与部署安全	推理服务、缓存、调度、资源隔离、侧信道、机密执行和模型服务供应链。
感知鲁棒性与物理攻击	视觉/多模态感知的对抗扰动、传感链路操纵、物理世界输入和鲁棒防御。

> 每个主题还保留排除规则与实验室相关性的公开依据。世界模型中的一般能力论文按背景阅读保留，不因出现 world model 就视为安全成果。

把方向变成可检验的问题

长期记忆安全 [C06]

先验证删除与撤销是否留下可观察残留；若只是再次演示跨会话投毒，应停止按新攻击立项。

影响终点。启用长期记忆的助手用户；攻击指令跨会话影响推荐或触发外传。历史PoC与推广注入尝试支持机制存在，当前删除后残留率未知

最近工作。AgentPoison；Memory Injection Attacks on LLM Agents via Query-Only Interaction；Trojan Hippo；Safeguarding LLM Agents against Long-Horizon Threats via Shadow Memory。本材料中的相关比较对象，不声称检索已穷尽。

局限。ShadowMem所测最长24轮，范围未覆盖广泛记忆投毒。Rehberger原图片外传链已修复。 删除原记录不必然等于删除派生状态，但本材料没有证明这种残留在当前产品中普遍存在。

验证任务。向授权测试记忆写入无害标记，允许摘要和检索，再删除或撤销来源并开启新会话。 固定模型、记忆后端、任务序列、检索次数和token预算，只改变删除范围及来源约束。

对照与终点。完整来源追踪后的级联删除、普通记录删除、ShadowMem、同预算完整历史judge。 记录残留标记、实际越权动作、合法记忆收益和恢复成本。

停止条件。若级联删除完全解决且没有额外效用代价，停止新增LLM防御；若不能稳定产生残留，停止该假设。

主要反对意见：残留可能只是缓存失效或清理实现错误，常规状态管理即可解决。 未知：当前后端的真实删除语义、可追踪派生状态以及受害发生率尚未确认。

工具与MCP安全 [C07]

把连接阶段实现漏洞与工具描述操纵分开；优先检验多工具组合或更新后已有授权是否仍覆盖最终动作。

影响终点。连接第三方MCP服务的用户与集成开发者；连接时主机执行、跨工具外传或收件人被替换。有具体历史版本和PoC；现客户端的残余风险须复测

最近工作。ACE；IsolateGPT；AgentDojo。本材料中的相关比较对象，不声称检索已穷尽。

局限。ACE实现限独立app和单query；IsolateGPT不防单app内部注入；mcp-remote对应漏洞已修复。 已发现连接器漏洞不等于MCP协议本身不安全，命中恶意工具也不等于最终危害成功。

验证任务。在合成服务中改变元数据或服务身份，测正常更新、恶意更新及跨工具任务。 固定客户端版本、模型、服务权限、任务和攻击预算；独立记录连接、规划、调用与提交阶段。

对照与终点。ACE、IsolateGPT、描述/版本固定加重新授权、执行参数白名单。 记录未经批准的副作用、正常更新阻断率、端到端完成率和审批次数。

停止条件。简单固定和执行约束在同效用下已解决时，停止追加复杂模型；仅复现已修复漏洞不作为新贡献。

主要反对意见：版本固定与确定性参数检查可能已覆盖全部风险，无须新语义检测器。 未知：当前实现、合法动态工具需求以及更新导致的真实事故规模未知。

把方向变成可检验的问题

Skill与工作流安全 [C08]

已有恶意Skill检测和按任务限制越权动作的直接工作；暂不做通用扫描器，先检验未见任务与认证状态下的残余越权。

影响终点。安装可复用指令包的开发者及其组织；执行恶意安装步骤、外传凭据或修改持久状态。公开平台快照与受控任务；确认恶意数和越权数均非全生态发生率

最近工作。SkillScope；"Do Not Mention This to the User"。本材料中的相关比较对象，不声称检索已穷尽。

局限。SkillScope §6指出重放非确定性、程序分离和认证夹具限制；野外研究§5.4指出60秒窗口、环境触发、沙箱规避和发布者集中。 框架验证不等于逐样本人工确认；157个确认恶意Skill是流程下界。任务完成也不等于输出或轨迹不变。

验证任务。重放正常与恶意Skill，在固定任务内改变认证和延时/跨会话触发，再用未见任务测权限约束。 固定agent、模型和执行预算；隔离发布者、近重复载荷与训练测试任务，记录沙箱失败。

对照与终点。SkillScope、原恶意Skill检测流程、规则扫描、直接删除与外部最小权限门控；同条件复现，不作跨论文性能排名。 记录残余越权及实际外传/写入、任务完成、输出/核心轨迹等价、误阻断和复核时间。

停止条件。先复现两篇近邻；若补齐夹具或普通执行门控即消除差异，或增益仅来自重复载荷，停止新方法主张。

主要反对意见：SkillScope已覆盖任务条件控制；差异可能只来自重放窗口或认证夹具不足。 未知：未见任务与认证状态的覆盖、长时触发和当前生态分布仍需验证；新方法空间尚未确定。

动作授权与执行 [C09]

不再以'执行前加一个LLM审核'立项；先找到确定性参数规则或既有capability架构处理不了的合法任务。

影响终点。批准agent执行操作的用户；批准的对象、接收方或数据范围与最终提交不一致。工具参数隐藏与跨工具收件人替换已有PoC；真实审批行为尚缺实测

最近工作。Defeating Prompt Injections by Design；AttriGuard；ACE。本材料中的相关比较对象，不声称检索已穷尽。

局限。CaMeL假设用户请求与既有记忆可信；AttriGuard排除完全显式委托且不能认证内容真实性。 文本看似符合用户偏好不构成授权，审批界面的可见性和执行器约束应分别核验。

验证任务。构造审批后改收件人、身份切换、权限撤销和合法外部数据依赖任务，检查执行时状态。 固定模型、工具、可见审批信息和任务；仅改变批准到提交间的状态变化。

对照与终点。参数绑定的不可变批准记录及执行时重查、CaMeL、ACE、AttriGuard。 记录错对象提交、撤销后执行、必要依赖误阻断、正常完成率和用户审批负担。

停止条件。若绑定参数与执行时校验解决全部病例，转为工程修复；不能证明必要语义依赖时停止新机制。

主要反对意见：这可能只是经典事务或TOCTOU问题，现成引用监控器已经足够。 未知：真实用户如何审批、哪些任务必须动态委托，以及许可撤销语义仍需确认。

把方向变成可检验的问题

网络安全Agent [C10]

把主终点从漏洞报告数量改为独特可复现发现及维护者处理成本；不要沿用'AI报告普遍虚假'作为当前前提。

影响终点。安全研究员与软件维护团队；重复或定级不清的报告占用审查资源，真实漏洞进入修复积压。curl与Firefox的直接经验；不代表所有项目或所有agent

最近工作。CyberGym；Understanding Implicit Trust Errors in Core Carrier Networks through Multi-Agent Flaw Discovery and Analysis；RACONTEUR。本材料中的相关比较对象，不声称检索已穷尽。

局限。Mozilla说明高严重性bug不等于完整exploit，模型和harness同时改善；新锚点的作者限制节尚未全文核验。 模型推理费用不能代表总成本；仅给出更多报告可能把负担转移给维护者。

验证任务。在获授权代码上比较静态报告、动态复现和带去重的完整流程，并由维护者盲评。 锁定模型、代码版本、信息条件、查询与人工预算，隔离已知漏洞和新发现。

对照与终点。现有fuzzing/静态分析、CyberGym式可执行验证、Mozilla所述复现与去重流程、同预算人工审计。 记录独特有效发现、正确严重性、修复回归、误报漏报及每项人工分钟。

停止条件。等预算下无法降低处理成本且未增加有效覆盖时停止；以少量精挑案例支撑泛化也应停止。

主要反对意见：收益可能来自新增算力或更成熟工程流程，而非新方法。 未知：公开材料未给统一总成本，真实新漏洞的漏检率与跨项目迁移未知。

医疗AI与医疗Agent [C11]

已有医疗问答、记忆和EHR工具基线；学生应先选可独立核验的停止/接管终点，缺少临床合作时不要承诺患者获益。

影响终点。患者、临床监督医生和医疗行政人员；误提交无效材料、遗漏附件、错误病史或漏掉人工接管。仿真行政任务与单中心受监督对话，非自主临床部署

最近工作。MedAgentBench；MDTeamGPT；MedAgent-Pro。本材料中的相关比较对象，不声称检索已穷尽。

局限。HealthAdmin环境简化登录和超时；AMIE全部对话有实时医生监督。三篇锚点的作者限制节尚未全文核验。 答案正确、流程完成和患者安全是不同终点；未触发安全停止不能证明自主执行安全。

验证任务。用合成患者构造材料过期、身份冲突和授权变化，核验应停止时是否停止并正确交接。 固定病例、EHR、模型和预算，分别改变临床信息与授权状态；先在离线仿真完成。

对照与终点。MedAgentBench原流程、确定性身份/材料检查、指南与工具工作流、受监督人工操作。 记录危险副作用、漏接管、误接管、复核分钟及最终环境状态。

停止条件。若规则校验已解决，转为实施验证；没有临床标注和伦理路径时停止患者效益主张。

主要反对意见：错误可能只需业务规则校验，无须新医学推理机制。 未知：真实医院数据与审批接口、医生一致性、低频危害及监督净成本未知。

把方向变成可检验的问题

水印与归属验证 [C12]

先指定谁要证明哪种来源，再决定做检测还是多用户归属；仅提高常规检测率已不足以界定新题目。

影响终点。模型服务商与依赖来源证据的验证者；伪造导致误指认，清洗导致来源漏检。特定水印方案的控制实验；本批没有真实客户归属纠纷证据

最近工作。A Watermark for Large Language Models；Watermark Stealing in Large Language Models；Provably Robust Multi-bit Watermarking for AI-generated Text。本材料中的相关比较对象，不声称检索已穷尽。

局限。Watermark Stealing作者当时未知对应线上部署；三篇锚点的完整限制及定理假设尚未复核。 统计检测不等于身份认证，多比特匹配率不等于大用户空间中的可靠归属，也不能证明模型被蒸馏。

验证任务。选定文本来源或用户标识任务，加入查询学习、改写、拼接和伪造，并单独测密钥轮换。 固定文本质量、长度、误报约束、用户规模、查询预算及攻击者是否知道算法。

对照与终点。经典统计水印、多比特鲁棒水印、Watermark Stealing自适应攻击，配无水印对照。 记录误指认、漏检、比特恢复、文本质量与攻击成本。

停止条件。若优势依赖放宽误报或损害质量则停止；未建立真实归属需求时不扩展为agent安全主方向。

主要反对意见：没有明确验证者与误指认后果，性能提升可能没有实际使用价值。 未知：部署者需求、密钥运维、当前方案与大规模用户归属错误代价仍未知。

蒸馏与反蒸馏 [C13]

在未授权复制、反蒸馏和安全迁移中选定一个终点；不把阻断API流量当成已阻止能力复制。

影响终点。模型开发商、API提供者与合法训练用户；能力被未授权复制，或防御误阻合法评测与学习。GTIG流量观测支持提取尝试存在，未独立展示学生最终能力

最近工作。Stealing Machine Learning Models via Prediction APIs；Undistillable；Cascading Adversarial Bias from Injection to Distillation in Language Models。本材料中的相关比较对象，不声称检索已穷尽。

局限。GTIG区分合法蒸馏与未授权活动；新锚点作者限制节尚未全文核验。 旧预测模型的精确提取不能外推到现代LLM；所测学生失败不构成不可蒸馏保证，水印也不是复制证据。

验证任务。在获授权教师与学生上比较软标签、硬标签、不同训练损失及外部数据，加入高频合法评测流量。 固定教师正常效用、学生架构与算力、查询/数据预算和权重访问权限。

对照与终点。普通蒸馏、Nasty Teacher、硬标签自适应训练、限流与行为检测；先确认能在选定模型上公平实现。 记录学生能力增益、复制保真度、教师效用、合法请求误阻和总成本。

停止条件。换硬标签或外部数据即消除优势，或教师效用明显下降时停止普遍反蒸馏主张；无法训练学生则只研究流量检测。

主要反对意见：效果可能只破坏某种损失函数，学生换训练方式即可恢复。 未知：真实授权边界、合法用户分布、现代LLM上的适用基线与下游训练证据未知。

怎样避免再次堆成论文清单

分类与聚类承担不同工作

自动建议仅使用标题中的对象和机制词，没有把旧六类或既有生成摘要当作训练真值。标题不能判断的 1452 条保留未归类。复核重点放在 memory、skill、tool、蒸馏、医疗和网络安全应用，纠正了内存侧信道、训练记忆、普通工具能力与 Agent 安全之间的混分。[C01][C02]

探索聚类采用标题 unigram/bigram 的 TF-IDF、128 维 SVD 和固定种子的 KMeans，设 48 簇。词汇簇帮助发现相近标题和遗漏词汇，没有语义真值、全篇威胁模型或时间变化证据，不能将簇大小解释成研究价值或领域占比。[C03]

影响按可观察后果判断

实践卡分别写明受影响者、失效终点、观察范围、证据强度和是否已修复。历史 PoC、市场样本、维护者经验及受监督医疗试验不能互相替代。网页保留相反或更新证据，包括维护者对 AI 漏洞报告质量变化的较新描述。[C05]

引用、关键词、代码分开解释

39 条有向引用边保留引用方原文、定位与版本。没有边只表示当前局部图未记录。关键词连线是共享标签，不是引用。旧引用数据库记录存在版本合并问题，因此不给总被引量排序。GitHub Star 是注明日期的整个仓库快照；公开代码、开放许可与独立复现分别核查。[C04][C14]

专项核读还纠正了 SkillScope 的类别重叠计数，并把任务数、任务完成、输出等价与轨迹等价分开呈现。具体版本与表格定位保留在论文卡中。[C16]

轻量打开与剩余工作

首页数据约 382 KiB。完整索引在进入论文库时加载，正文分为 61 个分片。页面采用本地相对路径与原生脚本，无 CDN、云端上传或服务器启动要求。请保留整个研究导航文件夹。[C15]

下一次维护应补当前工具版本的复现、关键论文全文限制节和最强对照。若现成的确定性权限、来源追踪或依赖管理已经解决同效用条件下的全部失败，应记录该结果并停止增加没有必要的模型机制。[C06 – C14]

公开来源与定位

来源发表时间不晚于 2026-11-01；本轮整合与页面更新日期为 2026-11-02。研究建议由本次分析提出，不是来源作者的原话。

1. ToxicSkills研究

   Luca Beurer-Kellner、Aleksei Kudrinskii、Marco Milanta、Kristian Bonde Nielsen、Hemang Sarkar、Liran Tal · 2026-02-05。定位：正文开头；Our methodology；The findings表格；Attack techniques；末尾第291行附近的成功入侵限制说明

2. CVE-2025-6514: Critical mcp-remote RCE Vulnerability

   Or Peles · 2025-07-09。定位：Who is affected；CVE-2025-6514 Summary；Figure 6、Figure 7

3. MCP Security Notification: Tool Poisoning Attacks

   Invariant Labs安全研究团队 · 2025-04-01。定位：Experiment 1: Attacking Cursor；确认框截图；MCP Rug Pulls；Experiment 2: Shadowing Tool Descriptions

4. Spyware Injection Into Your ChatGPT's Long-Term Memory (SpAIware)

   Johann Rehberger · 2024-09-20。定位：End-to-End Exploit Demonstration；Is Hacking Memories via Prompt Injection Fixed?；Timeline

5. Manipulating AI memory for profit: The rise of AI Recommendation Poisoning

   Noam Kochavi与Microsoft Defender Security Research Team · 2026-02-10。定位：正文开头；How it happens；对50多个prompts、31家公司、14行业的描述

6. Deceiving users with ANSI terminal codes in MCP

   Keith Hoodlet · 2025-04-29。定位：开头版本说明；How the attack works；Figures 1 – 2；Mitigating terminal deception attacks

7. The lethal trifecta for AI agents

   Simon Willison · 2025-06-16。定位：三种能力列表；This is a very common problem；GitHub MCP示例；Guardrails won’t protect you

8. ignore the slop

   Daniel Stenberg · 2026-10-22。定位：The slop is gone；AI talks too much；Everything is with AI now

9. Behind the Scenes Hardening Firefox with Claude Mythos Preview

   Brian Grinstead、Christian Holler、Frederik Braun · 2026-05-07。定位：Harnessing Models to Build a Hardening Pipeline；Upgrading the Models；FAQ中的271/423与practical exploit说明

10. The $1 Trillion Problem AI Still Can’t Yet Solve

    Suhana Bedi、Ryan Welch、Nigam Shah；采访整理者Rebecca Handler · 2026-04-15。定位：Testing AI on the Work No One Romanticizes；喂养泵案例；Why the Last Mile Is So Hard；Why This Matters Beyond the Benchmark

11. A Real-World Study of Patient-Facing AI in Primary Care

    Adam Rodman、Peter Brodeur、Jacob Koshy；采访整理者Jacqueline Mitchell · 2026-10-13。定位：Testing AMIE；Patient reception；Rodman关于真实工作流安全性和可接受性的说明

12. GTIG AI Threat Tracker: Distillation, Experimentation, and (Continued) Integration of AI for Adversarial Use

    Google Threat Intelligence Group · 2026-02-12。定位：Direct Model Risks；Case Study: Reasoning Trace Coercion；Table 1；Model Extraction and Distillation Attack Risks

13. Watermark Stealing in Large Language Models

    Nikola Jovanović、Robin Staab、Martin Vechev · 2024-02-29。定位：What is watermark stealing?；What are spoofing attacks?；What does this mean for LLM watermarking?

来源 · 论文与分类 [C02][C06–C14]

代表论文与依据

完整论文卡包含作者、版本、阅读深度、已有方法、局限及下一步；这里列出本说明使用的代表来源。主页依据为 Xinfeng Li 公开主页 的 About Me 与 Selected Publication。

1. AgentDojo: A Dynamic Environment to Evaluate Prompt Injection Attacks and Defenses for LLM Agents
   § 4防御讨论，pp.8 – 9； § 5，pp.9 – 10。
2. Defeating Prompt Injections by Design
   § 3与 § 3.1，PDF p.5； § 9，pp.23 – 24； § 10，pp.24 – 25。
3. ACE: A Security Architecture for LLM-Integrated App Systems
   § IV设计，PDF p.7；Appendix信息流/运行时讨论，PDF p.16。
4. AgentPoison: Red-teaming LLM Agents via Poisoning Memory or Knowledge Bases
   § 3威胁/方法； § 4.1指标；Limitations，PDF p.13。
5. Safeguarding LLM Agents against Long-Horizon Threats via Shadow Memory
   § 7，PDF p.14； § 6.1 AgentDojo设置，PDF p.10。
6. The Attacker Moves Second: Stronger Adaptive Attacks Bypass Defenses Against LLM Jailbreaks and Prompt Injections
   正式USENIX PDF： § 3物理页4 – 5； § 5物理页8（论文集p.1473）；Open Science物理页15（p.1480）
7. MDTeamGPT: Mitigating Context Collapse and Enabling Self-Evolution in Medical Multi-Agent Reasoning
   本轮主源摘要核验；官方或作者单篇页面 Abstract；本轮未声称阅读全文。
8. MedAgentBench: A Realistic Virtual EHR Environment to Benchmark Medical LLM Agents
   本轮主源摘要核验；官方或作者单篇页面 Abstract；本轮未声称阅读全文。
9. MedAgent-Pro: Towards Evidence-based Multi-modal Medical Diagnosis via Reasoning Agentic Workflow
   本轮主源摘要核验；官方或作者单篇页面 Abstract；本轮未声称阅读全文。
10. Understanding Implicit Trust Errors in Core Carrier Networks through Multi-Agent Flaw Discovery and Analysis
    本轮主源摘要核验；官方或作者单篇页面 Abstract；本轮未声称阅读全文。
11. RACONTEUR: A Knowledgeable, Insightful, and Portable LLM-Powered Shell Command Explainer
    本轮主源摘要核验；官方或作者单篇页面 Abstract；本轮未声称阅读全文。

> 基础资料为用户已有完整源数据与上一轮精选核读记录。来源指向公开论文，不表示对所有表格、附件或代码进行了独立复现。

来源 · 论文与分类 [C02][C06–C14]

代表论文与依据

完整论文卡包含作者、版本、阅读深度、已有方法、局限及下一步；这里列出本说明使用的代表来源。主页依据为 Xinfeng Li 公开主页 的 About Me 与 Selected Publication。

12. CyberGym: Evaluating AI Agents' Real-World Cybersecurity Capabilities at Scale
    本轮主源摘要核验；官方或作者单篇页面 Abstract；本轮未声称阅读全文。

13. A Watermark for Large Language Models
    本轮主源摘要核验；官方或作者单篇页面 Abstract；本轮未声称阅读全文。

14. Watermark Stealing in Large Language Models
    本轮主源摘要核验；官方或作者单篇页面 Abstract；本轮未声称阅读全文。

15. Provably Robust Multi-bit Watermarking for AI-generated Text
    本轮主源摘要核验；官方或作者单篇页面 Abstract；本轮未声称阅读全文。

16. Stealing Machine Learning Models via Prediction APIs
    本轮主源摘要核验；官方或作者单篇页面 Abstract；本轮未声称阅读全文。

17. Undistillable: Making A Nasty Teacher That CANNOT teach students
    本轮主源摘要核验；官方或作者单篇页面 Abstract；本轮未声称阅读全文。

18. Cascading Adversarial Bias from Injection to Distillation in Language Models
    本轮主源摘要核验；官方或作者单篇页面 Abstract；本轮未声称阅读全文。

19. SkillScope: Toward Fine-Grained Least-Privilege Enforcement for Agent Skills
    本轮关键章节核验（非全文通读）；v3 § 2.2、§ 4.1 – 4.3、§ 5.2/Table1、§ 5.3/Table8、§ 5.4/Tables10 – 12、§ 6；2026-09-10版本。

20. "Do Not Mention This to the User": Detecting and Understanding Malicious Agent Skills in the Wild
    本轮关键章节核验（非全文通读）；§ 3.1 – 3.5，Tables1 – 3；§ 5.4；Appendix F.3。

21. MCP Security Bench (MSB): Benchmarking Attacks Against Model Context Protocol in LLM Agents
    本轮主源摘要核验；官方ICLR 2026页面Abstract。

22. ContractGuard: Auditing Semantic Contracts of MCP Tools for Security Violations
    本轮关键章节核验（非全文通读）；作者CCS 2026稿 § 3 – 4；§ 5.1.2/Table3；§ 5.2；§ 6 Discussion。

> 基础资料为用户已有完整源数据与上一轮精选核读记录。来源指向公开论文，不表示对所有表格、附件或代码进行了独立复现。